### 1 REPORT

### 1. Implementation

a. Which algorithm do you choose in hw3-1?

利用 OpenMP 平行化 Floyd-Warshall algorithm 的 for 迴圈。

b. How do you divide your data in hw3-2, hw3-3?

hw3-2 \ hw3-3 :

Pivot block	Pivot row	Pivot row
Pivot column		
Pivot column		

Pivot block	Pivot row	Pivot row
Pivot column		
Pivot column		

利用範例的方法 divide data。

#### 作法:

除了 phase1 之外,phase2、3 將同一個 phase 拆分為多個部分利用 kernel 分開做,例如下圖為 phase2 的階段,圖中藍色區塊為 phase2 須處理、更新的 data,則須個別處理兩個部分 (kernel),分別為黃色框部分與紅色框部分,因為黃色部分的 size 為 1x2,因此分配此 kernel 的 grid size 為 1x2,而紅色部分則會被分配到 2x1 的 grid size 。

而在 kernel 的每個 block 中·若 block factor 為 k·則 create 出 k x k 的 threads 個別處理 block 中的 data。

Pivot block	Pivot row	Pivot row
Pivot column		
Pivot column		

c. configuration in hw3-2, hw3-3? And why?

hw3-2 \ hw3-3 :

■ # blocks: 詳見 b. 說明

■ # threads : (32, 32)

因為同一個 block 中 thread 最多可以開出 1024 條 · 因此想利用二維 thread 來管理每一個 block 進行計算 · 因此最多開出的 thread 數量為 32 x 32 。

■ blocking factor: 32

blocking factor 越大·越能夠縮減 shared memory、global memory 之間的搬移次數以提升效能·但因為被 maximum thread 的數量限制住了·所以 blocking factor 最多也只能開到 32 。

d. communication in hw3-3

利用 peer to peer 進行 communication, data 在 GPU memory 之間進行傳輸。

### 2. Profiling Results (hw3-2)

Data set: p11k1

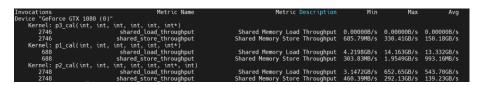
Occupancy:

Туре	Time(%)	Time	Calls	Avg	Min	Max
GPU activities:	97.90%	10.6179s	2746	3.8667ms	2.5920us	15.802ms

sm efficiency:

Metric Description	Min	Max	Avg
Multiprocessor Activity	2.23%	99.99%	98.93%

shared memory load/store throughput:



## global store throughput:

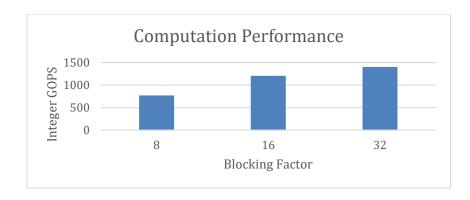
Invocations Device "GeForce GTX 1080 (0)"	Metric Name	Metric Description	Min	Max	Avg
Kernel: p3_cal(int, int, int, int,	int, int*)				
2746 Kernel: p1 cal(int, int, int, int,	gst_throughput	Global Store Throughput	95.367MB/s	77.333GB/s	42.890GB/s
688	gst_throughput	Global Store Throughput	110.57MB/s	492.22MB/s	450.00MB/s
Kernel: p2_cal(int, int, int, int, 2748	int, int*, int) gst throughput	Global Store Throughput	72.661MB/s	32.192GB/s	17.613GB/s

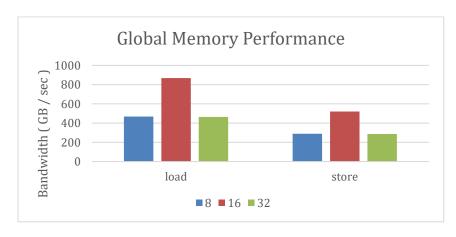
# 3. Experiment & Analysis

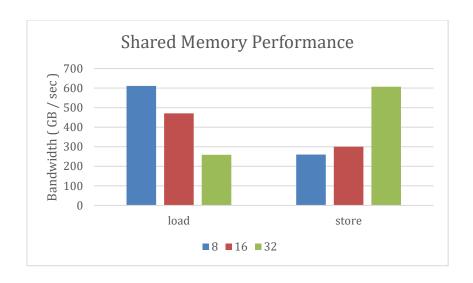
Blocking Factor (hw3-2)

Test case: C21.1

利用 –metrics inst\_integer 得出每個 kernel instruction 的數量·再利用 nvprof 得出 kernel 的 執行時間以及呼叫次數算出 integer GOPs 值。







由上述結果得知·增加 blocking factor 可以提高 interger GOPs·效能越佳·而我的程式最多只能調到 32·因此 data transfer 成為了 bottleneck。

## a. Optimization (hw3-2)

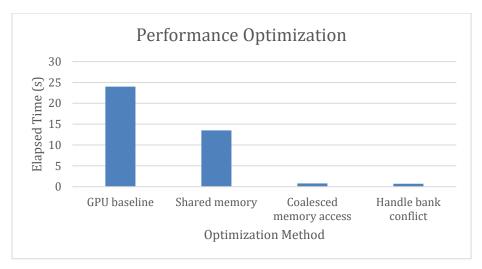
- Shared memory
  - 將 global memory 資料放入 shared memory 再進行計算以減少執行時間。
- Coalesced memory access

依照 row major 從 global memory array 中取出 data · 因為運算完後存入 array 時會變成 column major · 因此將預存資料進行轉置後再存入 global memory 中

Handle bank conflict

利用 Memory Padding 技術使同個 warp 的 thread 存取不同的 bank

### Test case : c20.1



# Time Distribution (hw3-2)

## b. Analyze the time spent in:

	C20.1	P11k1	P12k1
Vertex	5000	11000	11817
Edge	7594839	505586	3529066



### 4. Experience & conclusion

#### a. learned from this homework

這次對我的程式進行分析過後覺得自己的程式有很多地方需要改進,在我的方法中,block factor 最多只能開到 32,這對效能來說影響非常大,若 block factor 能開的更大,則可以讓更多的資料共享 shared memory,可大幅減少 shared memory 與 global memory 搬移的次數以及資料量,在我的程式裡有些 shared memory 與 global memory 之間的搬移過程也沒有用上全部的 thread,造成這些 thread 沒有功能且占據了 SM 導致效能下降。經過這次的經驗,下次再寫 CUDA code 時會再更徹底的思考如何開出合適的 block、thread 以增加效能。

#### b. Feedback

在寫作業時助教幫我們寫的 serial code 替我省下不少時間,會有更多時間專注在如何進行平行化。因為自己是第一次碰 CUDA,很多地方還不太熟悉,光是 debug 就花了蠻多時間,前面的 lab 作業還沒寫出來緊接著就需要開始寫 HW3,因此對我來說我覺得這次的 cuda labs 以及作業相較其他主題來說時間上排得稍些緊密,若提供更多的緩衝時間則會更好。